

Coverage-Constrained Human-AI Cooperation with Multiple Experts

Introduction

- Human-AI Cooperative Classification (HAI-CC)
 - 인간 전문성과 AI 역량의 trade-off를 해결하기 위한 방법론
 - AI의 정확도, 해석 가능성, 사용성 향상
 - 인간의 효율성, 의사결정 일관성 향상
 - Hybrid Intelligence 시스템을 목표로 개발
=> 정확도를 최대화 하면서 협력 비용을 최소화
- Learning to Defer (L2D):
AI가 직접 결정할지 사람에게 위임할지를 결정
- Learning to Complement (L2C):
AI와 인간의 결정을 종합하여 최종 결정

Introduction

- Single-Expert HAI-CC (SEHAI-CC)
 - 고정된 인간 전문가에게 의존/협력
 - => 비현실적이며 최선이 아닐 수 있음
- Multiple-Expert HAI-CC (MEHAI-CC)
 - 다중 전문가에게 의존/협력
 - => L2D와 L2C를 동시에 다루지 않음
 - => 무작위 선택으로 전문가 지식을 무시

Introduction

- 정확도와 협력 비용의 trade-off / 시스템 효율성, 효과성
- 기존 방법론 평가 방식: 정확도-커버리지 곡선
 - 커버리지: AI가 혼자 결정하는 비율 (100%: AI, 0%: 인간)
 - => 최적화 함수에 협력 비용을 고려하지 않음
 - => 불안정한 학습 과정
 - => 커버리지를 대략적으로 조정만 허용

Introduction

- 사후 평가 단계
 - rejector가 출력한 확률 저장
 - 리젝션 확률 기준으로 테스트 샘플 정렬
 - 목표 커버리지 값까지 점수가 가장 높은 샘플 defer
 - => 사후 평가는 실제 응용 분야에는 적합 X
 - => 사후 평가는 커버리지-정확도 trade-off 분석의 신뢰 저하
- 새로운 HAI-CC 방법 제안
Coverage-constrained Learning to Defer and Complement (CL2DC)

Introduction

- CL2DC
 - L2D와 L2C의 강점 결합
 - 다중 노이즈 레이블 주석의 학습 시나리오에 적절
 - defer와 complement의 시점 결정 + 가장 적합한 전문가 선택
 - 손실 함수에 제약 페널티 도입
- 기여: CL2DC 제안, 커버리지 제약 도입
- 데이터셋: CIFAR-100, Galaxy Zoo, HAM10000, NIH-ChestXray, MiceBone, Chaoyang
- SOTA 방법론과 비교하여 우수한 성능

Related Work

- Human-AI Cooperative Classification:
협업 비용을 최소화 하면서 정확도를 극대화하는 하이브리드 지능형시스템
- Learning to Defer (L2D):
최종 예측을 위해 전문가에게 defer해야 하는 경우를 결정하는 것이 목표
 - Bayes-optimal classifier와 다양한 대리 손실 함수 개발 중점
 - 실제 환경, 다수 인간 전문가 환경을 간과
 - 현재 L2D는 인간과 분류기를 통합하여 결정을 내리는 능력이 부족

Related Work

- Learning to Complement (L2C):
인간 전문가와 분류기의 예측을 결합하여 협력을 최적화하는 것이 목표
 - 단일 전문가 설정에 국한되거나 협력 비용을 최적화 하지 않음
 - 전문가의 특수성을 간과
 - 커버리지 값에서 알고리즘이 어떻게 작동하는지 평가 불가
 - 부분 자동화에서의 알고리즘 동작 연구 불가

Related Work

- Noisy Label 학습
 - 기존 연구는 데이터셋에 ground-truth 클린 어노테이션이 존재한다고 가정
 - 의료 영상 등 응용 분야에서 타당하지 않음
 - 학습 샘플당 다수의 노이즈 라벨이 존재함
- Learning with noisy labels (LNL)
 - ProMix, DEFT
 - 식별 가능성 문제 -> 강건한 학습을 위해 다수의 노이즈 필요할 수 있음을 의미
- Multi-Rater Learning (MRL): 샘플당 노이즈 라벨을 처리하는 방법
 - 다수의 노이즈 라벨을 사용하여 강건한 분류기 학습을 목표
 - UnionNet, CROWDLAB

Methodology

- 데이터셋: $\mathcal{D} = \{\mathbf{x}_i, \mathcal{M}_i\}_{i=1}^N$
- input sample: $\mathbf{x}_i \in \mathcal{X} \subset \mathbb{R}^d$
- 전문가 주석: $\mathcal{M}_i = \{m_{i,j} : m_{i,j} \in \mathcal{Y} = \{1, \dots, C\}\}_{j=1}^M$
- 확률 심플렉스: $\Delta^{K-1} = \{\mathbf{p} : \mathbf{p} \in [0, 1]^K \wedge \mathbf{1}^\top \mathbf{p} = 1\}$
- 전문가: $[M] = \{1, \dots, M\}$

Methodology

- 구성 요소
 - AI classifier

$$f_{\theta} : \mathcal{X} \rightarrow \Delta^{C-1}$$

- gating model:
 - AI, L2D, L2C 결정

$$g_{\phi} : \mathcal{X} \rightarrow \Delta^{2M+1}$$

- complementary module:
 - AI 모델 생성과 인간 전문가의 예측을 통합하여 최종 예측

$$h_{\psi} : \Delta^{C-1} \times \mathcal{Y} \times [M] \rightarrow \Delta^{C-1}$$

- Mixture of experts에서 영감 / 적응형 결정 시스템

Methodology

- Consensus labels
 - 일반적인 HAI-CC는 학습에 ground truth label 사용
 - 제안하는 방법은 정답 라벨 사용 불가
 - > MRL 방법인 CROWDLAB 사용

$$\hat{y}_i, \alpha_i = \text{CrowdLab}(\mathbf{x}_i, f_{\theta}(\mathbf{x}_i), \mathcal{M}_i) \cap \{\alpha_i > 0.5\}$$

- 품질 점수 α_i 와 합의 라벨 $\hat{y}_i$ 을 생성

Methodology

- Objective function

- 가중 평균 손실을 최소화하는 함수 (AI only, defer, complement)
- 가중치는 Gate model $g_{\phi}(\cdot)$ 에 의해 생성

$$\min_{\theta, \phi, \psi} 1/N \sum_{i=1}^N g_{\phi}^{\top}(\mathbf{x}_i) \ell(\mathbf{x}_i, \hat{y}_i, \mathcal{M}_i, \theta, \psi)$$

- $2M + 1$ 차원
- 분류기 cross-entropy 손실 $\ell(\cdot)$, M명의 인간 전문가, 보완 모듈의 cross-entropy 연결

Methodology

- Objective function

- L2D의 표준 가정: 인간 전문가 > 분류기
 - > 커버리지가 0에 가까워짐
 - > Gate model이 AI only 선택할 가능성 낮음
- 커버리지 제어를 위해 제약조건 통합

$$1/N \sum_{i=1}^N g_{\phi}^{(AI)}(\mathbf{x}_i) \geq \epsilon$$

- AI only 선택할 확률: $g_{\phi}^{(AI)}(\cdot)$
- 목표 커버리지: ϵ

Methodology

- Objective function

- 제약조건과 함께 최적화가 어려움
 - > 패널티 방법 사용
 - > 제약 있는 최적화를 제약 없는 문제로 변환
 - > 제약 위반: 손실 증가, 제약 충족: 손실 감소

$$\min_{\theta, \phi, \psi} 1/N \sum_{i=1}^N g_{\phi}^{\top}(\mathbf{x}_i) \ell(\mathbf{x}_i, \hat{y}_i, \mathcal{M}_i, \theta, \psi) + \beta_k c(\phi, \varepsilon)$$

- 반복 횟수: k
- $\beta_{k+1} = \lambda(\beta_k + k)$ ($\beta, \lambda > 0$ 은 하이퍼파라미터)
- $c(\phi, \varepsilon) = \left[\max \left(0, \varepsilon - \frac{1}{N} \sum_{i=1}^N g_{\phi}^{(\text{AI})}(\mathbf{x}_i) \right) \right]^2$

Experiments

- Datasets (Synthetic experts)
 - CIFAR-100
 - 전문가: 3명
 - 정확한 레이블 & 비대칭 레이블 노이즈 (50% 레이블링 오류)
 - HAM10000
 - 전문가: 2명
 - CIFAR-100과 유사한 설정
 - Galaxy Zoo
 - 전문가: 2명
 - CIFAR-100과 유사한 설정

Experiments

- Datasets (Real-world human's annotations)
 - Chaoyang
 - 전문가: 3명 (91%, 88%, 99%)
 - 88%, 91% 조합 & 전체 조합
 - MiceBone
 - 전문가: 8명 (84%~86%)
 - NIHChestXray
 - 전문가: 3명 (89%, 94%, 80%)
 - NIH-AO (airspace opacity) 분류

Experiments

- Evaluation
 - 커버리지에 따른 예측 정확도 (100%: AI 단독, 0%: 전문가 단독)
 - 3회 평균
 - 마지막 훈련 epoch에서 평가
- Baselines
 - SEHAI-CC (A-SM / DCE / DaF)
 - 주석을 무작위 샘플링 -> 단일 전문가를 시뮬레이션
 - MEHAI-CC (MultiL2D, LECODU)
 - 동일한 backbone, 하이퍼파라미터는 논문의 설정과 동일
 - 커버리지 제약조건 통합
 - 정확도-커버리지(0, 0.2, 0.4, 0.6, 0.8)

Experiments (Main results)




Figure 3: Accuracy-coverage curves of our method and competing SEHAI-CC (Mozannar et al. 2023; Charusaie, Fesharaki, and Samadi 2024; Wei, Cao, and Feng 2024; Cao et al. 2024) and MEHAI-CC (Zhang et al. 2025a; Verma, Barrejon, and Nalisnick 2023) methods.

Experiments

- Results - Accuracy-Coverage Curve
 - Trade-off 관계
 - AUACC (Area Under the Accuracy-Coverage Curve)
- Coverage
 - 기존 SOTA 모델을 능가
- 전문가 선택의 정밀도
 - 기존 MEHAI-CC: 전문가를 무작위로 선택하는 경향
 - CL2DC: 전문가의 특화 지식 파악 -> 적합한 전문가 선택

Experiments

- 정성적 분석
 - 상호 보완적 결정:
L2C 옵션이 성능 향상에 도움
 - 신뢰도 기반 라우팅:
Gate model 의 AI only 확률에 따라 적절한 라우팅

Experiments (Ablation Study)




Figure 4: Ablation studies on CL2DC in various settings: (a) different penalty coefficients on CIFAR-100, (b) varying human’s expertise on Chaoyang with 2 experts, (c) and (d) the influence of L2D and L2C on GalaxyZoo and Micebone, respectively, and (e) and (f) varying the number of experts on CIFAR-100.

Experiments

- 패널티 계수
 - λ : 줄이면 더 높은 정확도
 - β : 1에 가까운 다른 값에 대한 민감도 낮음
- 인간 전문가의 전문성 차이
 - Chaoyang2Exp vs Chaoyang3Exp
 - 전문성이 달라질 때도 견고함
- L2D, L2C의 유효성
 - w/o L2D: CL2DC가 우수
 - w/o L2C: CL2DC가 우수

Experiments

- 인간 전문가 수
 - 47개의 합성 전문가 추가 생성
 - 2명에서 3명일 때 크게 향상, 이후 안정화 (상호보완성)
- 추론 중 커버리지 값
 - AI only의 게이팅 출력값이 커버리지와 일치함
 - 다른 분포는 전문가 단독모델에 약한 선호

Conclusion

- Coverage-constrained Learning to Defer and Complement with Specific Experts (CL2DC) 방법 제안
 - L2D, L2C 강점 통합
 - 다중 노이즈 레이블이 존재하는 시나리오에서 우수
- 커버리지 제약 조건 구현
 - 혁신적인 패널티 방법을 손실 함수에 도입
- HAI-CC에서 SOTA달성
 - 실제 데이터셋 / 합성 다중 노이즈 레이블 데이터셋에 대한 포괄적인 평가에서 기존 SOTA보다 우수