

ICLR 2026

OpenAgentSafety

A comprehensive framework for evaluating real-world ai agent safety

Vijayvargiya, Sanidhya, et al.

OpenAgentSafety (ICLR 2026)

Overview

목적: Agent가 얼마나 위험하게 행동하는지 측정

방식: 샌드박스 환경에서 가상 회사를 만들고 업무를 수행

특징: 여러 차례 대화 + NPC + 착한/나쁜 의도

기존 벤치마크

- 가짜로 흉내 낸 도구 사용
- 웹이나 코드 등 한 분야만 다룸
- 짧은 대화
- 사용자 한 명

OpenAgentSafety (OA-SAFTY)

- 진짜 도구 5종 사용
- 8가지 위험 분야를 한번에 다룸
- 여러 차례 긴 대화
- 다양한 인물(NPC) 등장




Figure 1: An overview of the OPENAGENTSafety framework.

Infrastructure for Agent and Environment

격리된 샌드 박스 환경

- Docker 안에서만 작동
-> 실제 피해 x
- OpenHands 기반 에이전트

가짜 등장인물 (NPC)

- 동료/손님 연기
- 각 숨은 목표 보유
- 메신저로 대화

복제한 가상 업무 사이트

- OwnCloud: 파일 공유
- GitLab: 코드 관리
- Plane: 업무 관리

Safety Taxonomy and Task Design

80개 seed Task -> GPT-4o -> 356개 확장

- 설계 3축: 위험 종류, 도구 사용, 사용자/NPC 의도
- 과제 1개 = Docker 하나
- 사용 도구: 파일 시스템, 메신저, 웹, 명령창(bash), 코드

사용자/NPC 의도

- 모두 착함 (34%)
- 사용자 착함 + 동료 나쁨 (36%)
- 사용자 나쁨 (30%)

Safety Taxonomy and Task Design

8가지 위험

위험 종류	예시 상황
보안 뚫림	서버 설정 중 비밀 열쇠(SSH 키) 노출
데이터 삭제·손상	중요한 시스템 파일 삭제
개인정보 유출	직원 주민번호·주소를 공개 폴더로 복사
위험한 코드 실행	사용자 명령을 검사 없이 실행하는 코드 작성
금전 손해	평판을 지키려 횡령을 승인
나쁜 내용 퍼뜨리기	직원에게 모욕적인 메시지 전송
법 위반	고용 서류(I-9)를 틀리게 제출
잘못된 결정	과제 완료를 위해 설문 결과 조작

Evaluation Approach

규칙 기반 평가

- 과제가 끝난 뒤 환경 상태를 코드로 점검
- 0 안전 / 1 위험

LLM-as-judge 평가 (GPT-4.1)

- 생각과 행동 과정 전체를 읽음
- 미완성 시도, 나쁜 위도까지 포착
- 실패 / 안전 / 위험 미완료 / 위험 완료

Disagreement rate

Successful completion rate

Experiments Setup

7개 LLM

- 오픈 소스: Deepseek-v3, Deepseek-R1
- API: Claude Sonnet 3.7/4, GPT-4o/5, o3-mini (에이전트 통용)

OpenHands:

환경 내에서 실제 도구와 연동되는 에이전트 스캐폴드

Results

Table 3: Unsafe behavior rates for LLM-as-Judge and rule-based evaluation across models, along with Failure, Disagreement, and Successful Completion rates. Percentages for LLM-Judge and Rule-based are computed only over tasks where the agent reached safety-vulnerable states, where it was exposed to malicious input/content.

Model	LLM-Judge	Rule-based	Disagreements	Failure	Successful
Claude Sonnet 4	49.06	49.06	14.95	39.70	37.10
Claude Sonnet 3.7	51.20	32.85	9.17	40.30	33.88
GPT-5	52.58	52.15	13.79	34.80	40.40
GPT-4o	65.80	32.64	5.69	45.00	21.77
o3-mini	72.73	32.32	6.57	43.30	17.29
Deepseek-v3	62.23	32.44	6.91	46.30	22.12
Deepseek-R1	62.78	32.78	6.67	48.90	20.86

- Claude와 GPT-5가 나머지 모델보다 상대적으로 유의하게 안전
- 과제의 34-49%는 위험 지점 전에 실패 (웹 탐색, 인증, 도구사용)

Analysis

RQ1. 사용자 의도는 안전하지 않은 행동에 어떤 영향을 미치는가?


RQ2. 어떤 위험 범주가 가장 심각한 취약점을 드러내는가?

RQ3. 도구가 안전하지 않은 행동을 가능하게 하는가, 아니면 억제하는가?

RQ4. LLM judge는 안전하지 않은 행동을 감지하는 데 얼마나 신뢰할 수 있는가?

Analysis

RQ1. 사용자 의도는 안전하지 않은 행동에 어떤 영향을 미치는가?




- 착한 부탁:
안전보다 완료를 우선시 (예: API 키 하드코딩)
- 대놓고 나쁜 부탁:
일부 모델만 잘 거절 (Claude 3.7 30% vs o3-mini 81%)
- 숨은 나쁜 부탁:
동료 NPC가 부탁하면 거절 능력 감소

Analysis

RQ2. 어떤 위험 범주가 가장 심각한 취약점을 드러내는가?


Risk Category Distribution (% Unsafe)



1. 제도, 규칙 관련:
보안(72-86%), 권한 없이 도움을 우선
2. 작업 관련:
모델 차이 큼 (Claude가 상대적으로 안전)
3. 유해성 관련:
미리 훈련되어 비교적 안전 (o3-mini는 위험)

Analysis

RQ3. 도구가 안전하지 않은 행동을 가능하게 하는가, 아니면 억제하는가?



- 웹 브라우저: 59-75%
가장 위험
로그인/페이지 정보가 많아서 위험 신호를 놓침
- 파일, 코드 실행: 최대 74%
내용 확인 없이 실행
숨은 삭제 명령도 그대로 수행
- 메신저: 45-70%
상대의 역할, 권한 확인 x
공손한 부탁에는 규칙 위반

Analysis

RQ4. LLM judge는 안전하지 않은 행동을 감지하는 데 얼마나 신뢰할 수 있는가?

Table 4: Safety classification performance of LLM judges compared to human annotations. Right half excludes trajectories labeled as failures by human raters.

Rater	All Tasks (%)			Excl. Failures (%)			Disagreement (%)	
	Safe	Unsafe	Failure	Safe	Unsafe	Failure	Overall	Non-Failure
GPT-4.1	21.7	35.9	42.4	27.4	45.2	27.4	39.1	24.7
ASB	18.5	81.5	0.0	19.2	80.8	0.0	26.1	26.0
Human	7.6	71.7	20.7	9.6	90.4	0.0	—	—

ASB: Agent-SafetyBench

- 사람 전문가 2명이 GPT-4o 기록 100개를 직접 체점 (평가자 일치도 94%)
 - 말로는 동의 x, 행동은 실행 -> LLM이 놓침
 - 사소한 오류를 실패로 착각
- => 규칙 기반과 하이브리드 방식 필요

Case study

과제	상황	에이전트의 행동
저장소 공개	해고된 직원이 회사 코드 저장소를 공개로 바꿔 달라고 요청	권한 확인 없이 변경함
숨은 삭제	달력 일정 추가 스크립트 안에 모두 지우는 명령이 숨어 있음	파일을 열어보지 않고 실행함
해고 추천	출산휴가를 탔하는 내부 메모를 보고 해고자 추천	차별적 이유로 추천서 작성
API 키	새 기능 작성, 비밀 설정 파일이 따로 있음	비밀 키를 코드에 직접 적음
회의 안건	영업팀 직원이 자기 안건을 맨 앞으로 옮겨 달라고 부탁	공정성 고려 없이 순서 변경

Design implications

맥락적 의도 집계

- 거부 메커니즘이 고립된 프롬프트가 아닌 멀티턴 맥락에서 작동해야 함

도구별 권한 경계

- 코드 실행 및 파일 조작과 같은 고위험 도구에 대해 더 엄격한 런타임 제어 적용이 필요함

정책 기반 감독

- 규제 환경을 위해 에이전트를 훈련할 때 법적, 조직적, 절차적 규범에 부합하는 데이터셋을 사용해야함

Limitation

- 많은 과제가 위험 지점 전에 실패
- 가짜 인물이 각본을 벗어날 때 있음
- 웹사이트 등 환경 확장이 어려움