

Probabilistic Learning to Defer

Handling Missing Expert Annotations and Controlling Workload
Distribution

Introduction

- 인간
 - 새로운 개념을 학습하고 정확한 예측 가능
 - 데이터의 양이 기하급수적으로 증가하는 분야에서는 비용, 시간 등 비실용적이거나 불가능
- AI 모델
 - 방대한 양의 정보를 처리하는데 탁월
 - 편향에 취약

=> 이상적인 시스템: 인간의 신뢰성과 AI 모델의 효율성을 결합

Introduction

- Learning to Defer (L2D)
 - 인간과 AI의 강점, 약점을 파악 -> 낮은 비용, 높은 정확도
 - 모델이 확신을 갖지 못할 때 사람에게 위임

장점

- 인간, AI의 단독 성능을 능가

단점

- 모든 샘플에 대하여 인간의 주석 필요
- 작업 부하 제어의 부제

=> 데이터셋 크기 감소, 라벨링 다양성 감소

=> 일부 전문가 쏠림 현상과 편향 증가

Introduction

- Mixture of Experts (전문가 혼합 모델)
- Expectation-Maximisation (EM)

Contribution

- 전문가 혼합 모델을 통한 확률적 모델링 접근 방식 제안
- EM 알고리즘을 활용한 최적화
- 작업 부하 제어를 위한 E step 최적화의 제약 조건 도입

=> 누락된 전문가 주석 설정에서 능력 입증

=> 인간과 AI모델에 대해 원하는 작업 부하 제어 능력 입증

Background

- Learning to defer (Madras et al., 2018)
 - '특정 시나리오나 데이터셋에서 머신러닝 모델이 인간 전문가와 동등한 성능을 발휘 할 수 없다'는 관찰에서 시작
 - M명의 인간 전문가와 AI 분류기의 혼합
 - 쉬운 예제에 대한 분류 지원, 인간 전문가 호출 비용 감소
- C-way classification
 - Dataset:
 - Input sample:
 - Ground truth label:
 - x_i 에 대한 전문가 m의 주석:

$$\begin{aligned}\mathcal{D} &= (\{(\mathbf{x}_i, \mathbf{y}_i, (\mathbf{t}_i^{(m)})_{m=1}^M)\}_{i=1}^N \\ \mathbf{x}_i &\in \mathcal{X} \subseteq \mathbb{R}^d \\ \mathbf{y}_i &\in \mathcal{Y} = \{1, \dots, C\} \\ \mathbf{t}_i^{(m)} &\in \mathcal{Y}\end{aligned}$$

Background

1. draw a sample from data distribution: $\mathbf{x} \sim \Pr(\mathbf{x})$,
2. draw an annotation from each expert: $\mathbf{t}^{(m)} \sim \Pr(\mathbf{t}|\mathbf{x}, \theta_m) = \text{Categorical}(\mathbf{t}|f(\mathbf{x}; \theta_m))$,
3. draw a categorical variable to select an expert: $\mathbf{z} \sim \Pr(\mathbf{z}|\mathbf{x}, \gamma) = \text{Categorical}(\mathbf{z}|g(\mathbf{x}; \gamma))$,
4. draw a label from the belief of that expert: $\mathbf{y} \sim \Pr(\mathbf{y}|\mathbf{z}, \mathbf{t}) = \text{Categorical}(\mathbf{y}|\mathbf{t}^{(z)})$,

- Gating model

$$g(\cdot; \gamma) : X \rightarrow \{1, \dots, M + 1\}$$

- Classification model

$$f(\cdot; \theta_m) : X \rightarrow \Delta^{C-1} = \{v \in [0, 1]^C : v^\top \mathbf{1} = 1\}.$$

Background

- Objective

$$\begin{aligned} & \max_{\gamma, \theta_{M+1}} \sum_{i=1}^N \ln \Pr\left(\mathbf{y}_i, \prod_{m=1}^{M+1} \mathbf{t}_i^{(m)} \mid \mathbf{x}_i, \gamma, \{\theta\}_{m=1}^{M+1}\right) \\ &= \max_{\gamma, \theta_{M+1}} \sum_{i=1}^N \ln \Pr\left(\mathbf{y}_i \mid \mathbf{x}_i, \prod_{m=1}^{M+1} \mathbf{t}_i^{(m)}, \gamma\right) + \ln \Pr\left(\mathbf{t}_i^{(M+1)} \mid \mathbf{x}_i, \theta_{M+1}\right). \end{aligned}$$

- 첫 번째 항: Gating model 학습
- 두 번째 항: AI 분류기 학습

Missing Expert's Annotations

- 각 학습 샘플에 대해 일부는 전문가가 만든 주석, 일부는 누락 가정
 - 주석을 단 전문가 인덱스 집합 $D_{obs,i}$
 - 주석을 달지 않은 전문가 인덱스 집합 $D_{unobs,i}$

Rewritten Objective

$$\max_{\gamma, \{\theta_m\}_{m=1}^{M+1}} \sum_{i=1}^N \ln Pr(y_i, \prod_{m \in D_{obs,i}} t_i^{(m)} | x_i, \gamma, \{\theta\}_{m=1}^{M+1})$$

- γ 와 M 개의 전문가 및 AI 분류기 파라미터 학습

Missing Expert's Annotations

- Rewritten Objective에서 잠재 변수 z 와 $t^{(j)}$ 로 인해 log-likelihood를 계산 하기 어려움
- => EM Algorithm을 이용하여 lower-bound를 최적화

$$\begin{aligned} Q_i &= \mathbb{E}_{q(\mathbf{z}_i, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)})} \ln \Pr\left(\mathbf{y}_i, \prod_{m \in \mathcal{D}_i^{\text{obs.}}} \mathbf{t}_i^{(m)}, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)}, \mathbf{z}_i \mid \mathbf{x}_i, \gamma, \{\theta_m\}_{m=1}^{M+1}\right) \\ &= \mathbb{E}_{q(\mathbf{z}_i, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)})} \left[\ln \Pr\left(\mathbf{y}_i \mid \mathbf{z}_i, \prod_{m \in \mathcal{D}_i^{\text{obs.}}} \mathbf{t}_i^{(m)}, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)}\right) \right. \\ &\quad \left. + \sum_{j \in \mathcal{D}_i^{\text{unobs.}}} \ln \Pr\left(\mathbf{t}_i^{(j)} \mid \mathbf{x}_i, \theta_j\right) + \ln \Pr(\mathbf{z}_i \mid \mathbf{x}_i, \gamma) \right] + \sum_{m \in \mathcal{D}_i^{\text{obs.}}} \ln \Pr\left(\mathbf{t}_i^{(m)} \mid \mathbf{x}_i, \theta_m\right), \end{aligned}$$

$q(\mathbf{z}_i, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)})$: 잠재 변수의 posterior

Missing Expert's Annotations

- E step

$$\begin{aligned}
 q\left(\mathbf{z}_i, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)}\right) &= q(\mathbf{z}_i) \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} q\left(\mathbf{t}_i^{(j)}\right) = \operatorname{argmin}_q \operatorname{KL}\left[q(\mathbf{z}_i) \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} q\left(\mathbf{t}_i^{(j)}\right)\right. \\
 &\quad \left.\left\|\operatorname{Pr}\left(\mathbf{z}_i, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)} \mid \mathbf{x}_i, \mathbf{y}_i, \prod_{m \in \mathcal{D}_i^{\text{obs.}}} \mathbf{t}_i^{(m)}, \gamma^{(k)}, \left\{\theta_m^{(k)}\right\}_{m=1}^{M+1}\right)\right]\right] \\
 &= \operatorname{argmin}_q \operatorname{KL}\left[q(\mathbf{z}_i) \parallel \operatorname{Pr}\left(\mathbf{z}_i \mid \mathbf{x}_i, \gamma^{(k)}\right)\right] + \sum_{j \in \mathcal{D}_i^{\text{unobs.}}} \operatorname{KL}\left[q\left(\mathbf{t}_i^{(j)}\right) \parallel \operatorname{Pr}\left(\mathbf{t}_i^{(j)} \mid \mathbf{x}_i, \theta_j^{(k)}\right)\right] \\
 &\quad - \mathbb{E}_{q(\mathbf{z}_i) \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} q\left(\mathbf{t}_i^{(j)}\right)}\left[\ln \operatorname{Pr}\left(\mathbf{y}_i \mid \mathbf{z}_i, \prod_{m \in \mathcal{D}_i^{\text{obs.}}} \mathbf{t}_i^{(m)}, \prod_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbf{t}_i^{(j)}\right)\right],
 \end{aligned}$$

Missing Expert's Annotations

- M step

$$\begin{aligned}\gamma^{(k+1)}, \{\theta_m^{(k+1)}\}_{m=1}^{M+1} &\leftarrow \operatorname{argmax}_{\gamma, \{\theta_m\}_{m=1}^{M+1}} \sum_{i=1}^N Q_i(\gamma, \theta, \gamma^{(k)}, \{\theta_m^{(k)}\}_{m=1}^{M+1}) \\ &= \operatorname{argmax}_{\gamma, \{\theta_m\}_{m=1}^{M+1}} \sum_{i=1}^N \sum_{j \in \mathcal{D}_i^{\text{unobs.}}} \mathbb{E}_{q(\mathbf{t}_i^{(j)})} \left[\ln \Pr(\mathbf{t}_i^{(j)} \mid \mathbf{x}_i, \theta_j) \right] \\ &\quad + \sum_{m \in \mathcal{D}_i^{\text{obs.}}} \ln \Pr(\mathbf{t}_i^{(m)} \mid \mathbf{x}_i, \theta_m) + \mathbb{E}_{q(\mathbf{z}_i)} [\ln \Pr(\mathbf{z}_i \mid \mathbf{x}_i, \gamma)] .\end{aligned}$$

Constraining the Number of Assignments in the E-step

- Navie EM 알고리즘은 작업 부하 불균형 발생
- 전문가와 AI 모델의 균형

$$\frac{1}{N} \sum_{i=1}^N E_{e_q(z_i)}[z] = \frac{1}{N} \sum_{i=1}^N e_q(z_i) = \frac{1}{M+1} \mathbf{1}$$

- 작업 부하 제약

$$\epsilon_l \preceq \frac{1}{N} \sum_{i=1}^N e_q(z_i) \preceq \epsilon_u$$

- 모든 주석이 관측되는 경우 E step 에 통합
- 부분적으로 주석이 관측되는 경우 두 번째 E step 으로 간주

Constraining the Number of Assignments in the E-step

- 제약 최적화

$$\begin{aligned} \tilde{q}_i^* = \operatorname{argmin}_{\tilde{q}} \operatorname{KL} [\tilde{q}(\mathbf{z}_i) \| q^*(\mathbf{z}_i)], \forall i \in \{1, \dots, N\} \\ \text{s.t.:} \quad \boldsymbol{\varepsilon}_l \preceq \frac{1}{N} \sum_{i=1}^N \tilde{q}(\mathbf{z}_i) \preceq \boldsymbol{\varepsilon}_u. \end{aligned}$$

- Lagrange multipliers

$$\boldsymbol{\lambda}_u^*, \boldsymbol{\lambda}_l^* = \operatorname{argmin}_{\boldsymbol{\lambda}_u, \boldsymbol{\lambda}_l \geq 0} \boldsymbol{\lambda}_u^\top \boldsymbol{\varepsilon}_u - \boldsymbol{\lambda}_l^\top \boldsymbol{\varepsilon}_l + \frac{1}{N} \sum_{i=1}^N \ln \sum_{\mathbf{z}_i} q^*(\mathbf{z}_i) \exp\left(-(\boldsymbol{\lambda}_u - \boldsymbol{\lambda}_l)^\top \mathbf{z}_i - 1\right)$$

- 잠재 변수의 제약된 posterior

$$\tilde{q}^*(\mathbf{z}_i) \propto q^*(\mathbf{z}_i) \exp\left(-(\boldsymbol{\lambda}_u^* - \boldsymbol{\lambda}_l^*)^\top \mathbf{z}_i - 1\right)$$

Constraining the Number of Assignments in the E-step

- 작업 부하를 유연하게 분배
- 정확도-커버리지 곡선 분석에 용이
 - 현재 관행에는 한계점이 존재
 - 인간 전문가와 분류기에 대한 선택 비용 변경
 - M 단계에 다른 손실 항 추가 $L = L_{M-step} + \zeta(Pr_{M+1}(z|x; \gamma) - c)^2$
 - Gating model의 예측 값을 사용하여 순위를 매긴 후 임계값 조정(post-hoc)

=> 제안 하는 방법이 하이퍼파라미터 튜닝 없이 작업 부하를 효과적으로 분배

=> 학습-테스트 일관성을 갖춘 모델을 생성, 사후 인간 개입 없이 결정


Experiments

- 벤치마킹
 - 합성 데이터셋 (Cifar-100)
 - 비대칭 레이블 노이즈를 따르는 전문가 시뮬레이션
 - 실제 데이터셋 (NIH-ChestXray, Chaoyang, MiceBone)
 - 전문가의 주석을 무작위 제거
 - 누락 데이터셋 구성


Baselines

- Naïve L2D
- SSL (semi-supervised learning) 변형 1
- SSL (semi-supervised learning) 변형 2

Results



(a) Cifar-100 - 2 experts - 0.3 miss. (b) Cifar-100 - 2 experts - 0.5 miss. (c) Cifar-100 - 2 experts - 0.7 miss.



(d) Chaoyang - 2 experts - 0.3 miss. (e) Chaoyang - 2 experts - 0.5 miss. (f) Chaoyang - 2 experts - 0.7 miss.

Figure 3: Comparison of coverage - accuracy curves between different L2D methods on a variety of datasets, each at a different missing rate.

Results

Table 1: Area-under-coverage-accuracy-curve ($\times 100$) of different learning to defer methods when dealing with missing annotations on different datasets (larger is better). Note that at no missing annotation (or zero missing rate), all methods are simplified to the same learning algorithm, and hence, share the same result.

Dataset	N ^o experts	Missing rate	Naive L2D	MixMatch	FixMatch	Probabilistic (ours)
Cifar-100	2	0	75.38	75.38	75.38	75.38
		0.3	72.80	66.95	67.39	73.33
		0.5	70.83	66.80	67.27	72.13
		0.7	67.68	65.52	66.52	71.19
NIH-AO	1	0.2	91.79	92.26	91.41	93.40
Chaoyang	2	0	89.49	89.49	89.49	89.49
		0.3	87.48	86.90	86.86	90.50
		0.5	87.46	88.12	86.66	90.03
		0.7	87.09	87.11	86.92	88.41
	3	0.5	89.94	88.55	90.33	91.07
MiceBone	8	0	79.58	79.58	79.58	79.58
		0.3	79.67	81.02	81.87	83.48
		0.5	80.30	82.19	82.12	83.69
		0.7	81.31	80.60	82.55	83.10

Ablation Study on Controllable Workload

- 불균형 설정
 - 각 인간 전문가의 워크로드가 제어 X
- 균형 설정
 - 모든 인간 전문가에게 워크로드가 균등하게 분배




Figure 4: (a) and (b) show comparisons of two different workload constraints on Chaoyang dataset with 50% missing annotations per expert, where in the *imbalanced* setting, $\varepsilon_l = 0$ and $\varepsilon_u = 1$ for each human expert, while in the *balanced* setting, $\varepsilon_l \approx \varepsilon_u = (1 - \text{coverage})/M$ for each human expert, and (c) coverage - accuracy curve on MiceBone at 30% missing rate.

Related Work

- Learning to defer
 - Learning to Reject에서 확장
 - AI가 확신이 없을 때 판단을 거부하는 기능을 넘어, 그 판단을 인간 전문가에게 위임하여 최종 결정을 내리는 방식
 - Classifier (AI 모델)
 - Gating Model (위임 모델)
 - 초기에는 단일 전문가, 최근에는 다중 전문가

Related Work

- 전문가 주석 누락
 - 기존 L2D 연구는 모든 데이터에 모든 전문가가 주석을 달아야함
 - > 비현실적인 가정
- 주석 누락 해결을 위해 2단계 학습 진행
 - 준지도 학습(SSL)으로 가짜 주석 생성
 - 이를 이용해 L2D 학습
 - > 1단계의 오류가 2단계로 전이될 위험

Limitations and Discussion

- Scalability
 - 각 인간 전문가를 개별적인 모델로 표현
-> 전문가의 수가 늘어날수록 GPU 사용량 증가
- Deferral at low coverage
 - 모호한 사례를 전문가에게 넘기면 정확도 상승, 모델의 신뢰도 상승
but, 전문가의 업무 부하가 증가, 진단이나 결정 속도저하 가능
- Dynamic expert performance
 - 인간 전문가의 숙련도는 시간이 지남에 따라 향상되거나, 과도한 업무로 인해 일시적으로 감소할 수 있음

Conclusion

- 실무적 한계 극복
 - 누락된 주석과 전문가 선택 과정을 잠재 변수 (Latent Variables)로 모델링하고, 이를 EM 알고리즘을 통해 확률적으로 최적화
- 효율적인 자원 배분
 - E step에서 제약 조건 최적화 메커니즘을 통합하여 인간 전문가와 AI 간의 작업량을 효율적이고 유연하게 분배 가능하게 함
- 성능 검증
 - 합성 데이터셋, 실제 의료 데이터셋에서 기존 방법들 보다 뛰어난 성능을 보임