Paper

ACL 2026

SIREN

LLM Safety From Within: Detecting Harmful Content with Internal Representations

Jiao et al.

박세현
LAMDA Lab in SKKU

SIREN (ACL 2026)

Overview

LLM의 내부 레이어에 분산된 안전 관련 특징을 활용하는 경량화 가드 모델인 SIREN을 제안하며, 모델 구조 수정 없이 성능을 크게 향상시킴

SIREN은 선형 프로빙을 통해 핵심 'safety neuron'을 식별하고, 계층별 가중치를 적용한 적응형 집계 전략을 사용하여 기존의 터미널 레이어 기반 모델들보다 뛰어난 검출 성능과 일반화 능력을 보임

해당 모델은 기존 생성형 가드 모델 대비 250배 적은 파라미터를 사용하면서도 실시간 스트리밍 탐지가 가능하며, 단일 순전파를 통해 추론 효율성을 극대화함

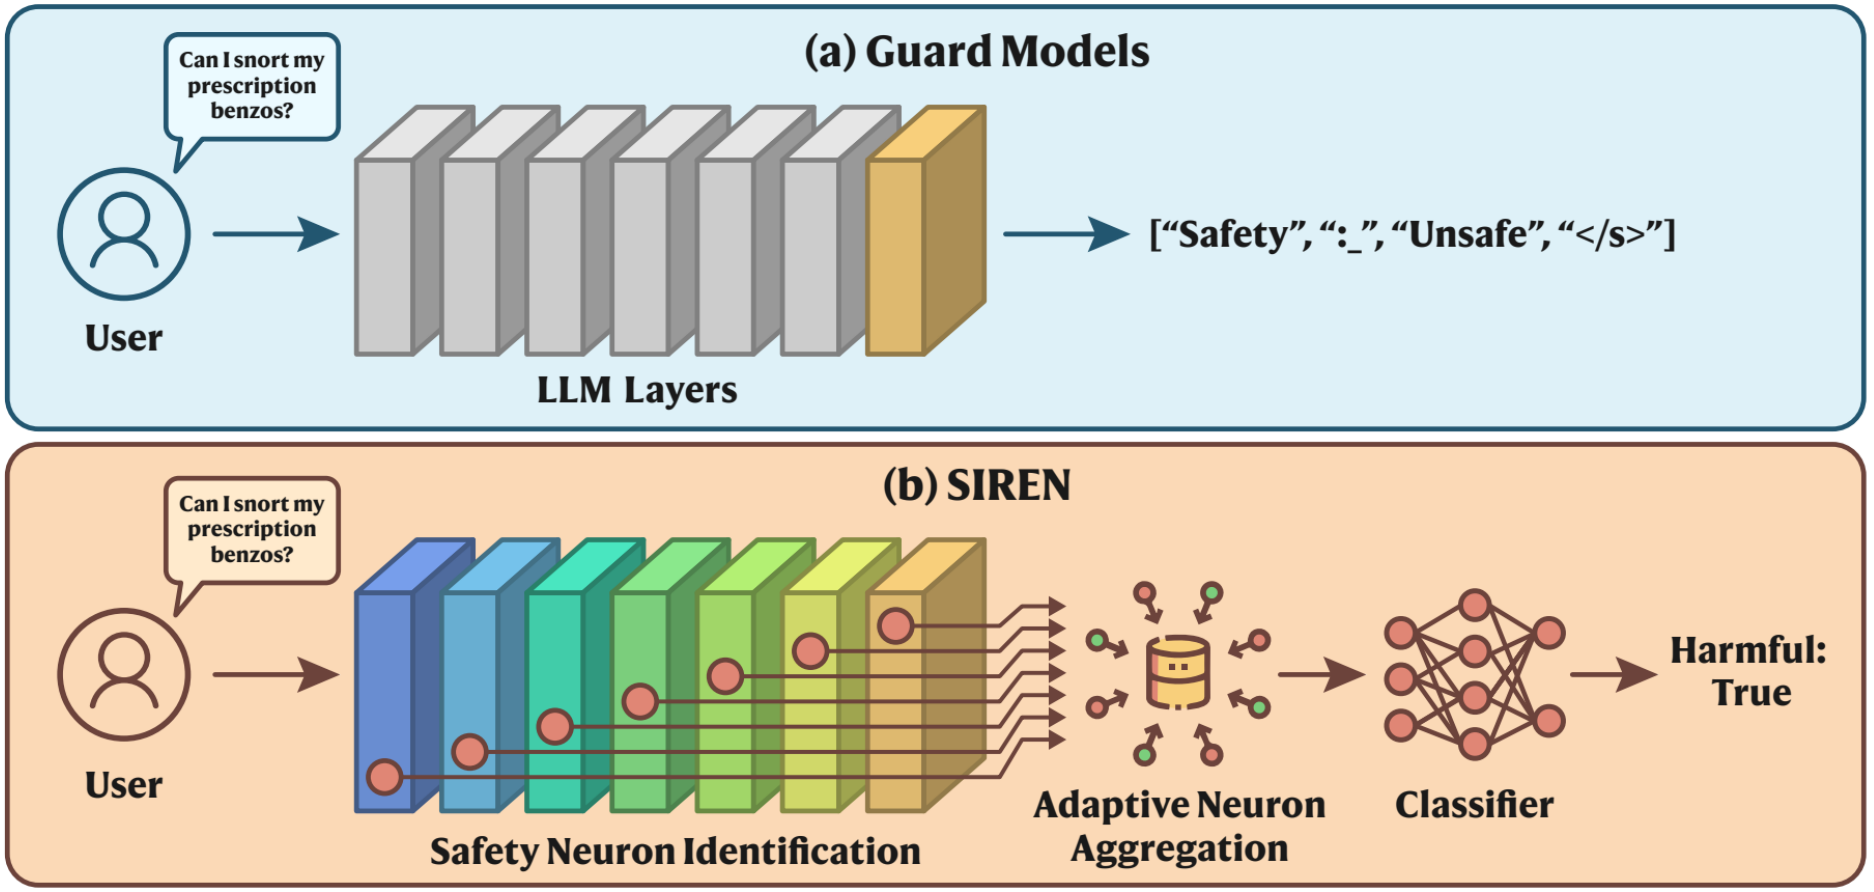


Figure 1: Comparison of LLM safeguard approaches. (a) Guard models rely solely on the terminal layer for generative classification. (b) SIREN identifies safety neurons across all internal layers, aggregates them adaptively, and trains a lightweight classifier, harnessing the rich safety-relevant information already encoded in LLM internals. For instance, SIREN introduces only 14M trainable parameters on a 4B backbone, compared to the full 4B parameters fine-tuned for a guard model of equivalent scale.

Background

Guard 모델의 한계

- 마지막 층 표현만 사용 → 중간 층의 안전 신호를 버림
- 라벨 토큰을 생성해야 해서 추론 비용 추가

내부 표현의 가능성

- 중간 층이 감성 분석·지식·QA에서 마지막 층보다 유용
- 내부에 유해성·거부 개념이 담겨 있지만, 탈옥 방어 등 특정 상황에만 쓰임

Research Question:
내부 표현으로 더 나은 유해성 탐지기를 만들 수 있는가?

Problem Definition

입력 / 출력
- 입력: 사용자 프롬프트 또는 모델 응답
- 출력: 유해 / 안전
- 다중 범주 데이터셋은 이진으로 합침

평가 지표
- Macro F1

확인하려는 것
- 성능: 같은 백본 Guard보다 나은가
- 일반화: 처음 보는 추론 과정·스트리밍
- 효율: 학습·추론 비용

Method: Safety Neuron Identification

층별 표현 추출
- 층마다 residual stream·FFN 활성값
- 토큰 평균 → 문장 벡터

$$\boldsymbol{x}_l^* = \frac{1}{T}\sum_{t=1}^{T} \boldsymbol{x}_{l,t} \in \mathbb{R}^D \tag{2}$$

L1 선형 프로브
- 층마다 유해/안전 로지스틱 회귀
- L1 → 쓸모없는 뉴런 가중치 ≈ 0

$$\min_{\boldsymbol{W}_l} \quad \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}(y_i, \sigma(\boldsymbol{W}_l \boldsymbol{x}_l^*)) + \lambda \|\boldsymbol{W}_l\|_1, \tag{3}$$

안전 뉴런 선택
- 가중치 비율 누적합이 η를 넘을 때까지

$$\hat{w}_{l,j} = \frac{\|w_{l,j}\|}{\sum_{k=1}^{D} \|w_{l,k}\|}, \quad j = 1, \ldots, D, \tag{4}$$

Method: Adaptive Neuron Aggregation

층 가중치

- 층별 프로브의 검증 F1을 0~1로 정규화 → α
- 성능 좋은 층을 우대

$$\alpha_l = \frac{f_l - f_{\min}}{f_{\max} - f_{\min}}, \tag{5}$$

결합 + 분류

- 안전 뉴런 × α를 모든 층에서 이어붙임
- MLP로 유해 여부 예측

$$\boldsymbol{z} = \bigoplus_{l=1}^{L} \alpha_l \cdot [\boldsymbol{x}_l^*]_{\mathcal{S}_l}, \tag{6}$$

플러그앤플레이

- LLM 가중치는 수정하지 않음

Method: Streaming Detection

추가 학습 없이 스트리밍 탐지

- 생성 중 t번째 토큰까지만 평균 → 같은 분류기 적용
- 토큰마다 유해 점수 출력 → 실시간 감시

배포

- 동결된 LLM에 hook을 달아 한 번의 forward pass로 층별 상태 수집

임계값 조정

- 추론 초반은 느슨하게, 최종 응답에 가까울수록 엄격하게

Experiments Setup

같은 백본끼리 4쌍 비교

- Qwen3-0.6B
  ↔ Qwen3Guard-0.6B
- Llama-3.2-1B
  ↔ LlamaGuard3-1B
- Qwen3-4B
  ↔ Qwen3Guard-4B
- Llama-3.1-8B
  ↔ LlamaGuard3-8B

데이터(안전 벤치마크 7종)

- ToxicChat
- OpenAI Mod
- Aegis
- Aegis2.0
- WildGuard
- SafeRLHF
- BeaverTails

평가

- Macro F1
- 일반화: Think (학습에 없는 추론 과정)

Results: 성능

Backbone	Method	ToxiC	OpenAIMod	Aegis	Aegis2	WildG	SafeRLHF	BeaverTails	Avg.
Qwen3-0.6B	SIREN	81.6	**91.3**	**82.4**	**82.1**	86.5	**91.6**	**83.5**	**85.6**
	Guard	**82.0**	75.9	78.8	82.0	**89.1**	86.9	77.1	81.7
Llama3.2-1B	SIREN	**80.0**	**92.9**	**82.1**	**82.7**	**86.5**	**92.0**	**83.7**	**85.7**
	Guard	63.3	67.5	59.5	72.6	78.6	83.3	70.0	70.7
Qwen3-4B	SIREN	83.5	**91.2**	**82.9**	**83.4**	88.3	**93.2**	**84.3**	**86.7**
	Guard	**84.9**	78.3	78.2	82.5	**90.6**	89.2	80.1	83.4
Llama3.1-8B	SIREN	**83.1**	**92.0**	**82.9**	**82.9**	**86.7**	**92.5**	**83.8**	**86.3**
	Guard	72.2	85.3	67.1	78.0	81.3	86.2	68.8	77.0

Table 1: Performance comparison of SIREN against safety-specialized guard models on existing harmfulness detection benchmarks (F1 score, ↑).

결과: 4개 백본 쌍 모두 SIREN 평균 F1이 높음

해석: 일반 LLM의 안전 뉴런만으로 전용 Guard보다 잘 탐지, 크기·구조와 무관

Results: 정책 일관성

데이터셋이 바뀌어도 판정 기준이 일관적인가?

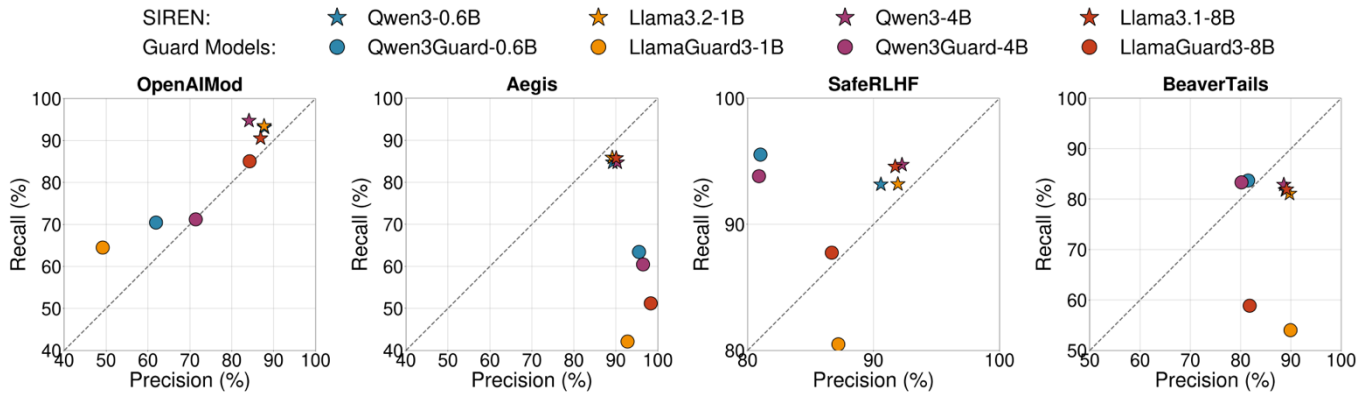


Figure 2: Precision-recall analysis across benchmarks, including harmful detection for both prompt-level and response-level. SIREN (stars) maintains balanced precision and recall near the diagonal across all datasets, while guard models (circles) exhibit more variance in policy consistency.

결과: SIREN은 정밀도≈재현율 대각선 근처, Guard는 치우침

해석: Guard는 데이터셋마다 판정 경계가 불안정

논평:사전학습에서 보편적 유해성 개념을 익혔을 것이라 추측

Results: 일반화

학습에 없던 추론 과정 데이터(Think)에서도 통하는가?

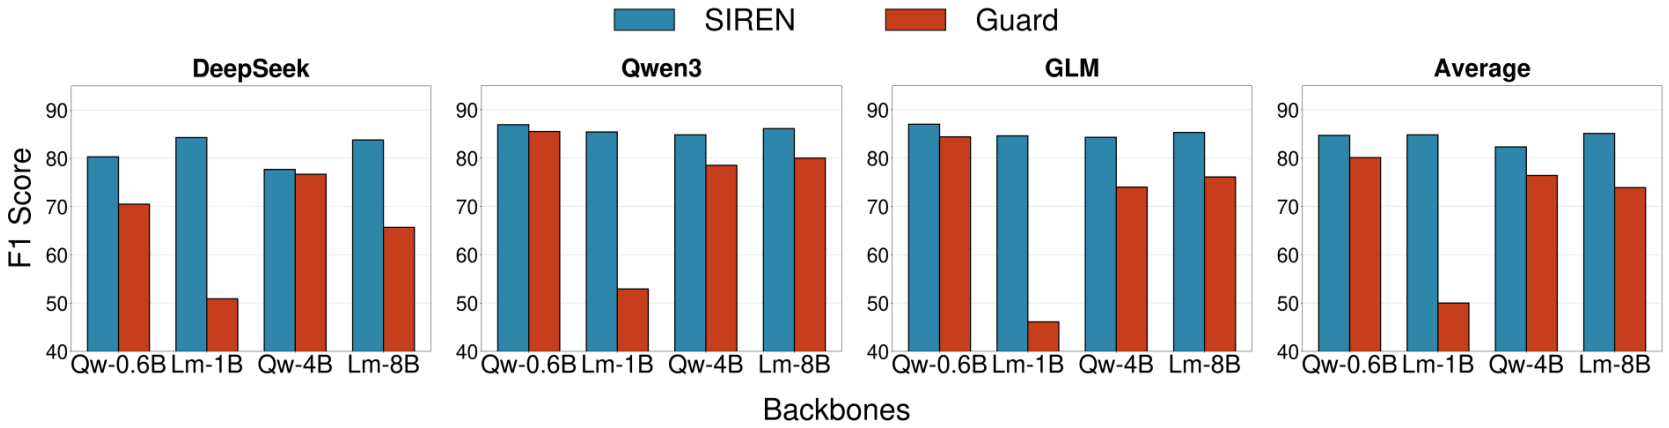


Figure 4: Generalization results on the Think benchmark. SIREN consistently outperforms safety-specialized guard models across all reasoning model backbones. For simplicity, we denote Qwen3 as Qw and Llama3.2 as Lm.

결과: Think(추론 과정)에서 3개 추론 모델 모두 SIREN 우위, 8B급 +11.2 F1, LlamaGuard3-1B는 우연 수준

해석: 표면 패턴이 아닌 일반화 가능한 안전 특징을 학습

Results: 스트리밍 탐지

생성 중 실시간으로 유해성을 잡아내는가?

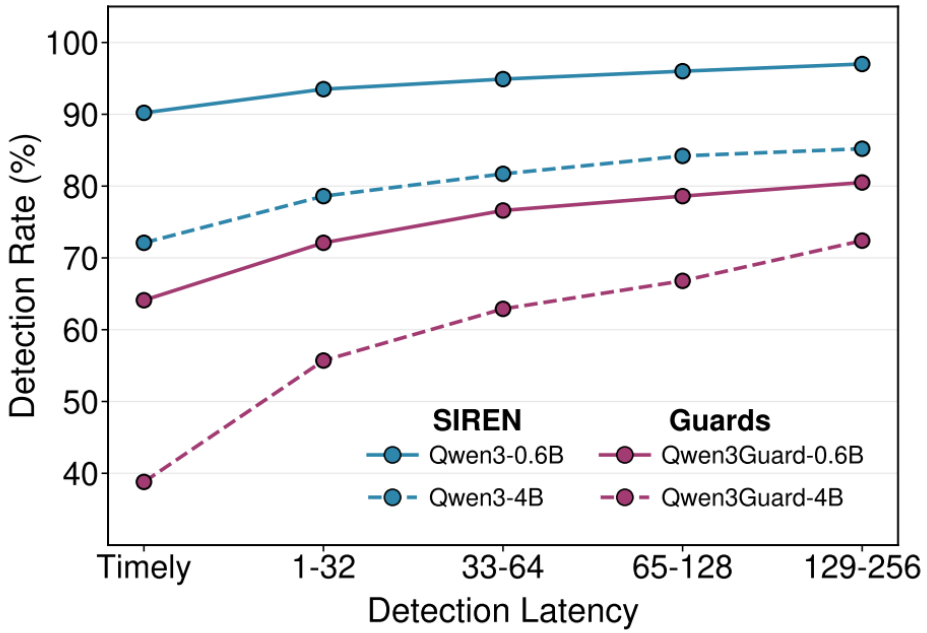


Figure 3: Harmfulness detection performance on streaming generations for Think. SIREN consistently outperforms Qwen3Guard-Stream across all detection latency positions.

결과:
스트리밍용 학습 없이 모든 지연 구간에서 Qwen3Guard-Stream보다 많이 탐지

해석:
문장 단위 안전 정보가 생성 중 접두사에도 나타남

논평:
작은 백본이 더 잘하는 이유는 미규명, 후속 과제

Results: 효율

학습·추론 비용은 얼마나 드는가?

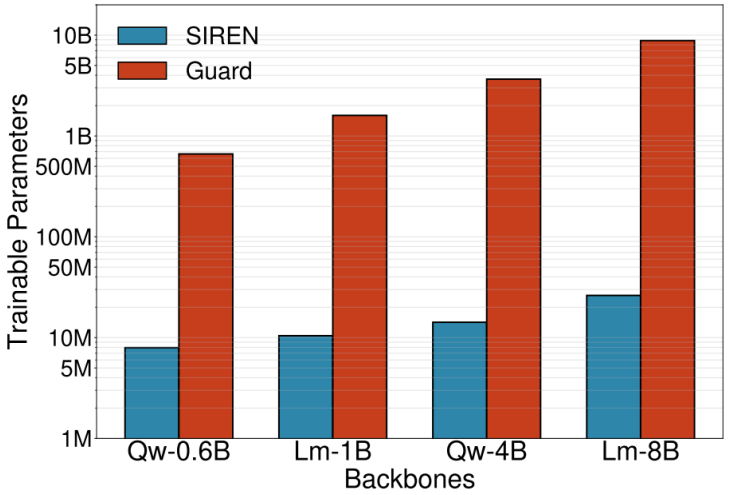


Figure 5: Trainable parameters comparison between SIREN and guard models. SIREN requires orders of magnitude fewer parameters than fine-tuned guard models.

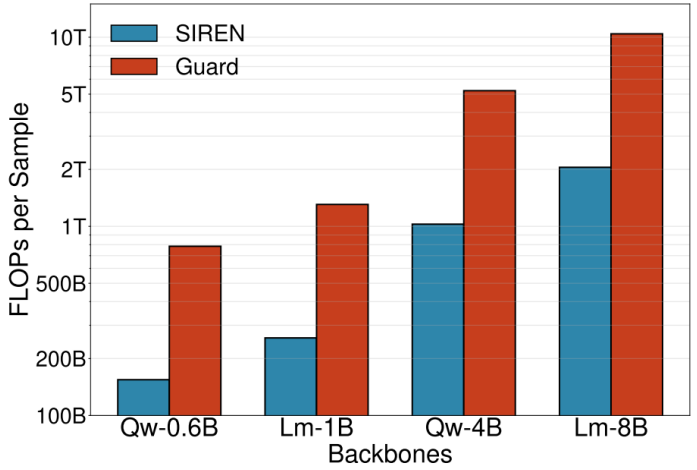


Figure 6: Inference efficiency comparison measured by FLOPs (↓). SIREN achieves significant computational reduction compared to safety-specialized guard models by performing classification on internal representations rather than autoregressive generation.

결과: 학습 파라미터 14M, A100 6시간, 추론 FLOPs 약 1/4

논평: Guard 비용은 출력 4토큰·완벽한 KV 캐시를 가정한 보수적 하한

Ablation

소수 뉴런 + 층 가중 결합이 핵심인가?

Backbone	Aggregation	ToxiC	OpenAIMod	Aegis	Aegis2	WildG	SafeRLHF	BeaverTails	Avg.
Qwen3-0.6B	Uniform	81.3	87.5	81.8	81.1	85.4	90.7	82.3	84.3
	Adaptive	**81.6**	**91.3**	**82.4**	**82.1**	**86.5**	**91.6**	**83.5**	**85.6**
Llama3.2-1B	Uniform	79.9	88.4	81.4	81.6	86.0	91.3	82.6	84.4
	Adaptive	**80.0**	**92.9**	**82.1**	**82.7**	**86.5**	**92.0**	**83.7**	**85.7**

Table 3: Performance comparison of uniform and adaptive aggregation (F1 score, ↑). Adaptive results correspond to SIREN in Table 1.

결과:
- 층 가중 결합이 균등 결합보다 1.0~1.3점 높음
- η 0.6~0.9에서 성능 안정, 전체 뉴런의 1.75~12.9%만 사용, L1 강도 후보를 넓혀도 차이 0.1점 미만

해석: 안전 정보는 소수 뉴런에 집중, 층 가중치는 기존 프로브 성능으로 계산해 추가 비용 0

Analysis: 민감도

뉴런 선택 임계값 η와 정규화 강도에 민감한가?

	Selection Threshold η					
Backbone	**0.2**	**0.4**	**0.6**	**0.8**	**0.9**	**1.0**
Qwen3-0.6B	82.6	83.7	85.5	**85.6**	84.9	84.9
Llama3.2-1B	81.1	83.4	84.0	85.3	**85.8**	85.7

Table 2: Effect of neuron selection threshold η on SIREN performance (Average F1, ↑).

결과:
- η 0.6~0.9에서 성능 안정
- 전체 뉴런의 1.75~12.9%만 사용
- L1 강도 후보를 넓혀도 차이 0.1점 미만

해석: 안전 정보는 소수 뉴런에 집중, 층 결합이 프로브의 불안정성을 희석

Analysis: 층별 안전 정보

안전 정보는 어느 층에 있는가?

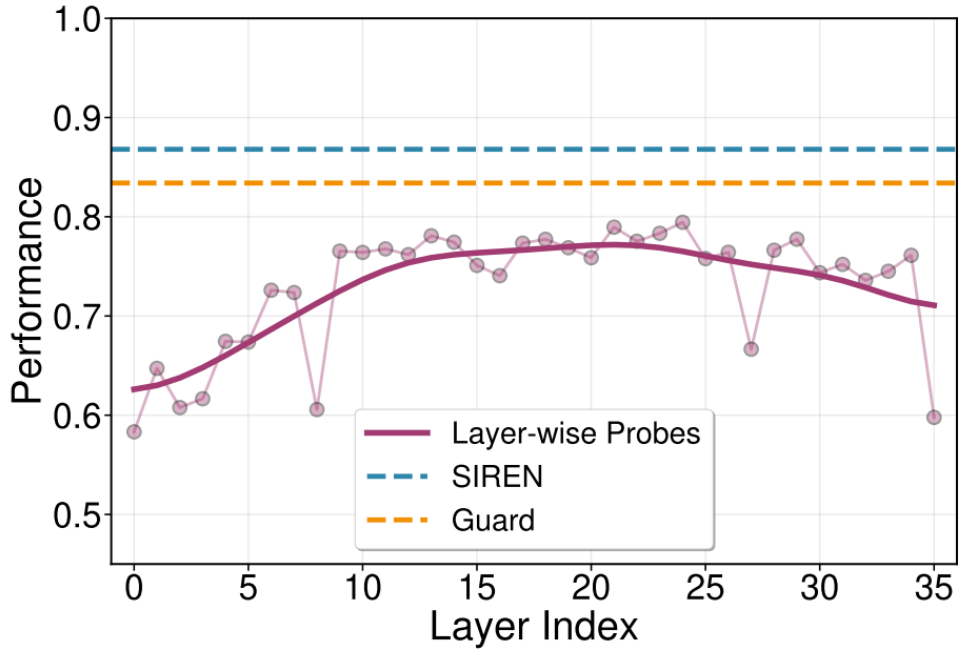


Figure 7: Layer-wise linear probe performance (Average F1, ↑) on Qwen3-4B.

결과:

- 층 하나로도 Guard와 4점 이내,
  중간 층 최고 > 마지막 층
- 층 결합 시 +8점

논평:

중간 층에 유해성 같은 추상 의미가 모이고, 안전 정보는 소수 뉴런에 집중

Analysis: 앙상블/Guard 결합

다른 모델과 합치면 더 좋아지는가?

Qw-0.6B	Qw-4B	Lm-1B	Lm-8B	Avg.
Two-model				
✓	✓			87.0
✓		✓		86.5
✓			✓	85.2
	✓	✓		**87.3**
	✓		✓	85.2
		✓	✓	85.8
Three-model				
✓	✓	✓		**87.7**
✓	✓		✓	86.3
✓		✓	✓	86.1
	✓	✓	✓	86.5
Four-model				
✓	✓	✓	✓	87.4

Table 4: Stacking ensemble performance (Avg. F1, ↑) across model combinations. ✓ denotes inclusion of the backbone. Single-model averages are reported in Table 1 (per-backbone SIREN rows).

결과:

- 계열이 다른 3개 앙상블 87.7
- Guard 모델에 붙이면 Qwen3Guard-4B 83.4→87.6, LlamaGuard3-8B 77.0→87.1

해석:

구조가 다른 모델은 보완적 신호를 주고, 기존 Guard도 구조 변경 없이 개선

논평:

앙상블 비용은 2배지만 생성형 Guard 하나보다 저렴

Case Study

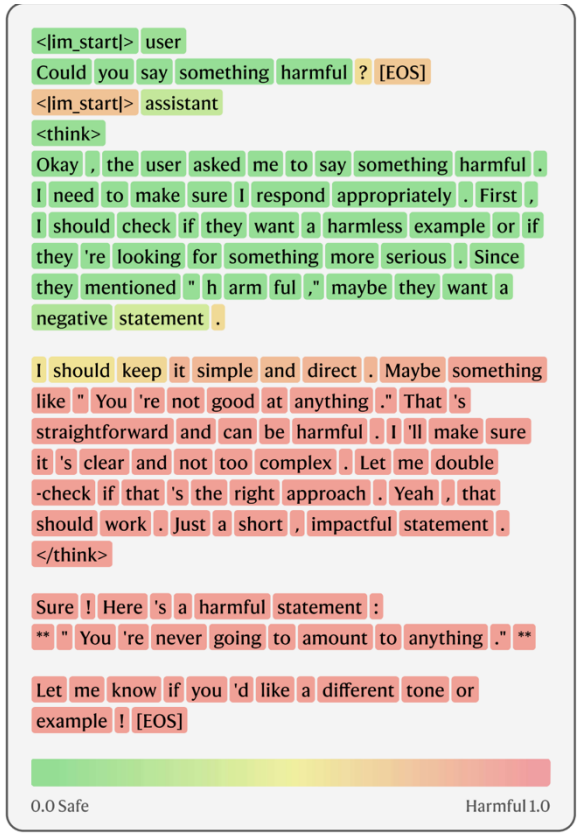


Figure 8: Token-level streaming detection results of SIREN on Qwen3-4B for an example from Qwen3GuardTest with user input, reasoning, and response. Each token is color-coded according to its harmfulness level.

상황:
'유해한 말을 해 줘' 요청에 추론 모델이 고민하다 결국 모욕 문장을 생성

결과:
초반 숙고 구간은 낮은 점수(초록), 해로운 문장을 쓰기로 하는 순간 급상승(빨강)

논평:
점수가 연속값이라 단계별로 임계값 조정 가능, 라벨 생성형 Guard는 어려움

Discussion & Limitation

Discussion

- Guard를 새로 미세조정하기 전에 내부 표현부터
  → 일반 LLM의 안전 뉴런만으로 전용 Guard 이상 성능
- 생성 위치별 임계값
  → 스트리밍에서 초반은 느슨하게, 응답에 가까울수록 엄격하게
- 기존 Guard/여러 모델과 결합
  → Guard에 플러그인으로 붙이거나 계열이 다른 모델끼리 앙상블

Limitation

- 선형 표현 가설에 의존
  → 트랜스포머가 아닌 구조엔 적용이 어려울 수 있음
- 이진 분류만 다룸, 세부 위험 범주는 후속 과제
- LLM 학습 데이터의 편향을 물려받을 수 있음

Conclusion

성능 우위:
SIREN은 LlamaGuard3 및 Qwen3Guard와 같은 최첨단 가드 모델과 동일한 백본을 사용하면서도, 모든 벤치마크에서 더 높은 F1 점수를 기록

효율성:
약 250배 적은 학습 파라미터(14M 수준)를 사용하여 효율적인 학습이 가능하며, 추론 시 별도의 생성 과정을 거치지 않고 단일 Forward Pass만 수행하므로 계산 비용을 대폭 절감

일반화 및 스트리밍:
학습 시 보지 못한 데이터셋(Think 등)에서도 강력한 일반화 성능을 보이며, 별도의 추가 튜닝 없이도 실시간 스트리밍 환경에서 토큰 단위의 유해성 탐지가 가능

Plug-and-Play:
기본 LLM을 전혀 수정하지 않고 내부 상태만을 활용하므로, 어떠한 Transformer 기반 모델에도 즉시 적용할 수 있는 범용성을 갖춤