논문: https://doi.org/10.48550/arXiv.2503.10167

"*Well, Keep Thinking*"

Adaptive Injection Decoding

박세현
LAMDA Lab in SKKU

LLM의 문제

- 광범위 과제에서 강력 → 복합 추론에는 한계…
- 프롬프트 엔지니어링
  - Few-shot
  - Chain-of-Thought (CoT)

  → 큰 제작 비용, 높은 문구 민감도

- 미성숙한 추론
  - Silence: 답을 생성하지 못하고 <eos>로 종료
  - No Reasoning: 질문 반복, 의미없는 패턴 출력 등 추론 x
  - Incomplete Reasoning: 추론 o, 중도 탈선/조기 종료로 불완전한 답 생성

❖ 프롬프트 의존 x, 디코딩 기반 대안 필요 (test-time scaling 포함)

LLM의 미성숙한 추론

- Silence
  모델이 초기에 추론 시도를 포기하거나 종료 신호에 빨리 굴복
- No Reasoning
  형식적 문장/패턴 생성이 논리를 대체하며, 답변처럼 보여도 추론 근거 x
- Incomplete Reasoning
  방향은 맞았으나 유지 실패

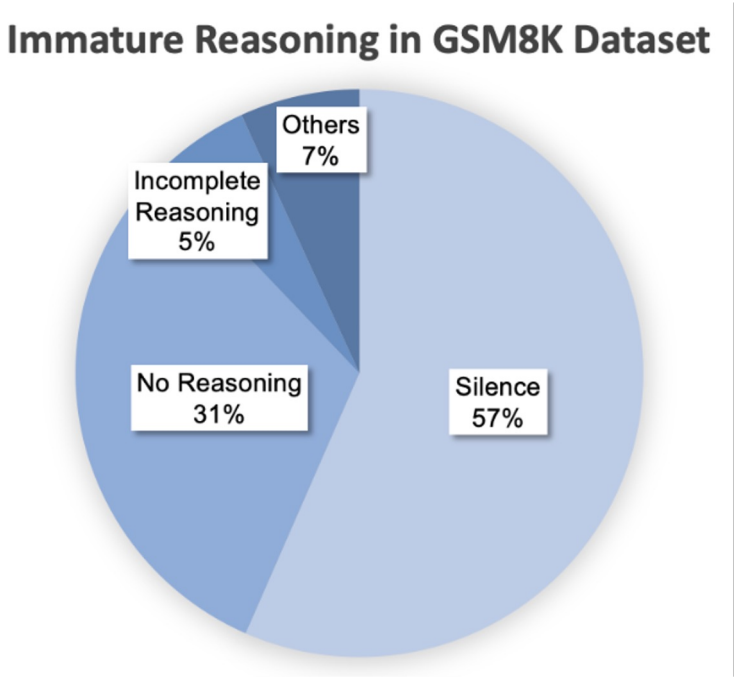

❖ 단순 성능 상향 기법이 아닌 실패 원인에 정조준한 개입

AID (Adaptive Injection Decoding)

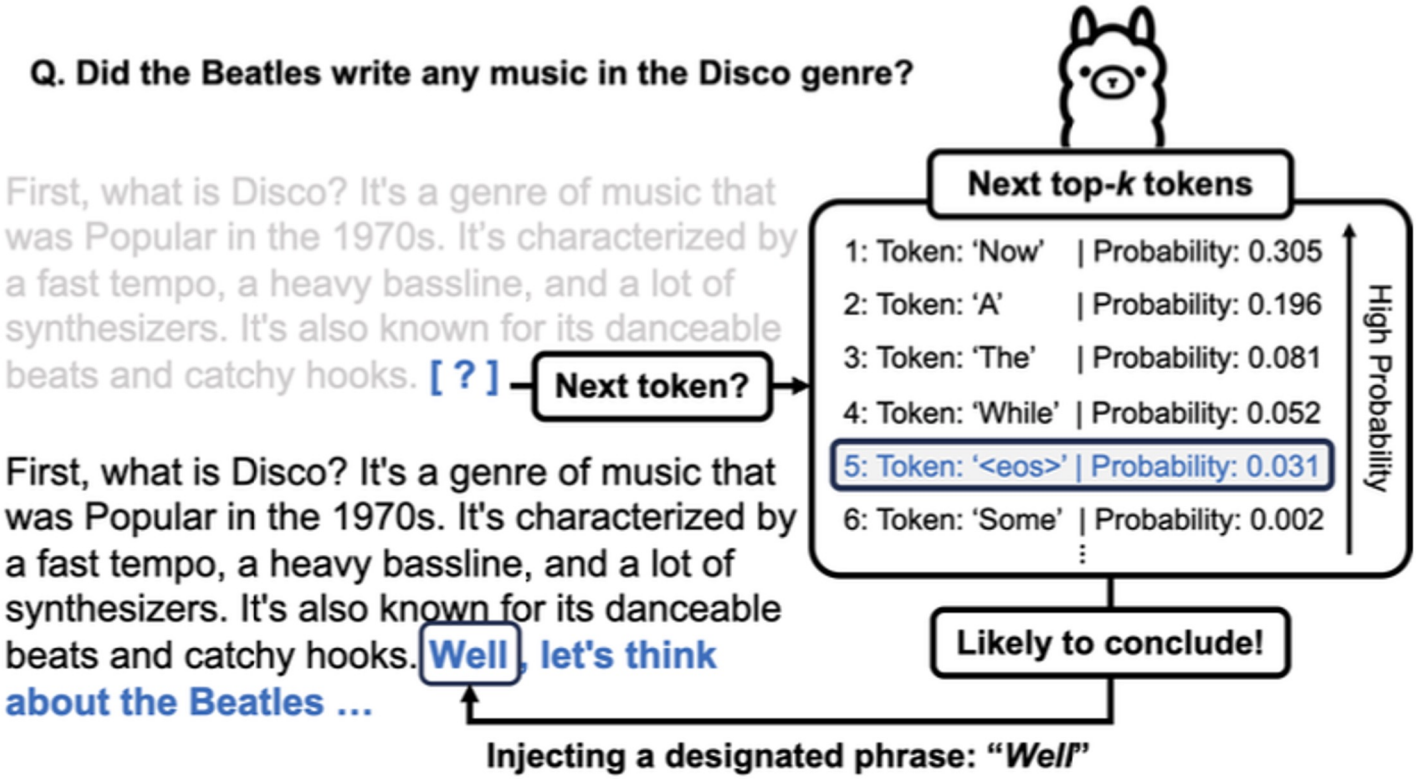

AID (Adaptive Injection Decoding)

- 디코딩 중 <eos> 토큰이 위험 신호로 감지되면, 미리 정한 문구(“Well”)를 다음 토큰으로 삽입해 조기 종료/탈선을 막는 동적 개입 전략

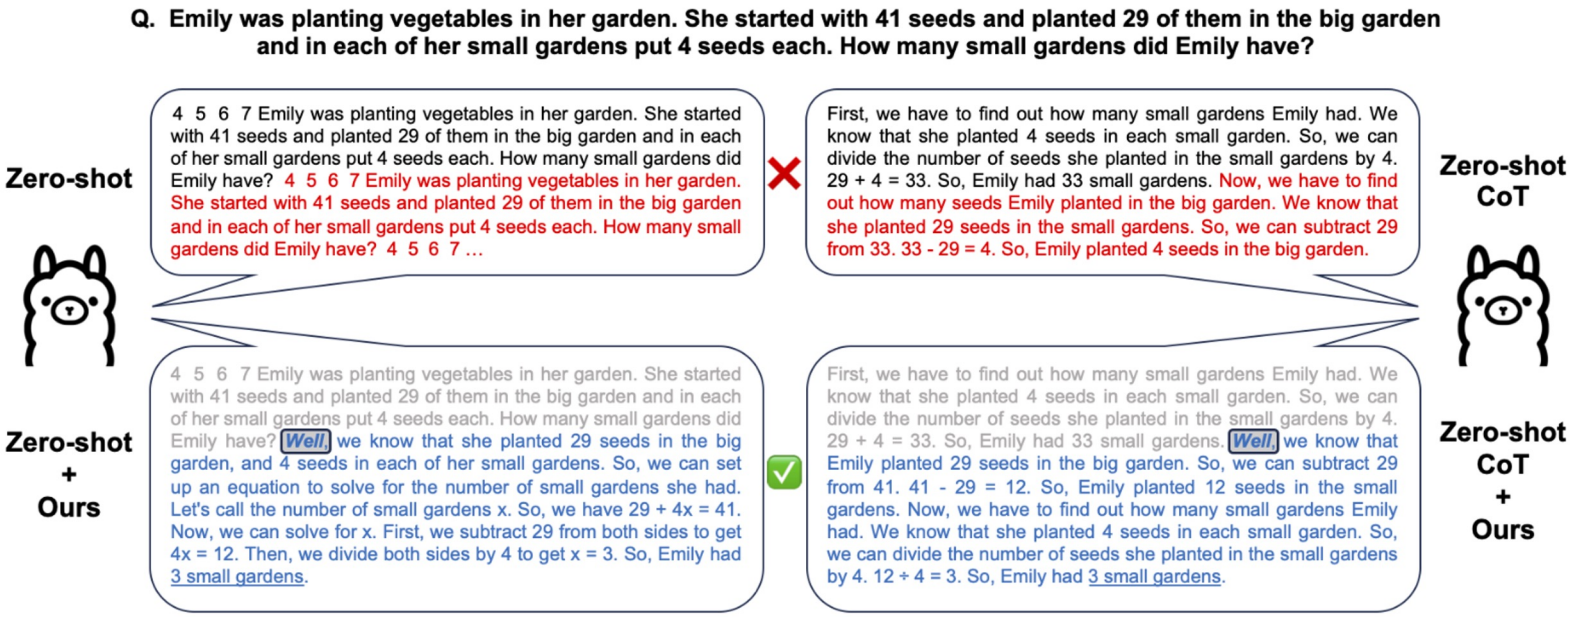

AID (Adaptive Injection Decoding)

- Algorithm
  - Greedy 디코딩 루프에 조건 추가
    (<eos>가 top-k 안에 들어오면 p 삽입)

1. 응답 버퍼 r = [], 단일 주입 보장 플래그 cont = False
2. 루프에서 매 스탭 p, top_k 계산
3. top_k에 <eos> 등장하면 주입어를 다음 토큰으로 추가, cont = True로 변경

Algorithm 1 Adaptive Injection Decoding

```
Require: model f(·), prompt x, top-k k, injection prompt p, using zero-shot-CoT zs_cot, maximum length max_length
if zs_cot then
    x ← x + "\nLet's think step by step."
end if
r ← [];
cont ← False
for i = 1 to max_length do
    p ← f(x)
    top_k ← TopK(p, k)
    if not cont and <eos> ∈ top_k then
        x ← x + p
        r ← r + p
        cont ← True
        continue
    end if
    next_token ← arg max(p)
    if next_token is <eos> then
        break
    end if
    x ← x+ next_token
    r ← r+ next_token
end for
return r
```

AID (Adaptive Injection Decoding)

- Algorithm
  - top_k 기반 트리거
    - 모델 마다 <eos> 거동이 다름 → 폭넓은 트리거 필요
  - 단 한 번만 주입
    - 과도한 개입은 흐름을 깰 수 있음
    - 1회 주입으로 안정화 뒤 자율 전개 유도
  - Greedy 디코딩 호환
    - 실용적 계산비용으로 폭 넓게 성능 향상
- 하이퍼파라미터 & 주입 문구
  - k (top_k)
  - p (injection phrase)

Algorithm 1 Adaptive Injection Decoding

Require: model $f(\cdot)$, prompt x, top-k k, injection prompt p, using zero-shot-CoT `zs_cot`, maximum length `max_length`

```
if zs_cot then
    x ← x + "\nLet's think step by step."
end if
r ← [];
cont ← False
for i = 1 to max_length do
    p ← f(x)
    top_k ← TopK(p, k)
    if not cont and <eos> ∈ top_k then
        x ← x + p
        r ← r + p
        cont ← True
        continue
    end if
    next_token ← arg max(p)
    if next_token is <eos> then
        break
    end if
    x ← x+ next_token
    r ← r+ next_token
end for
return r
```

평가 설정

- 모델
  - 주요: Llama-3.1-8B, Mistral-7B-v0.3, Gemma-3-7B
  - 스케일 검증: Llama-3.2-1B, QwQ-32B
- 데이터셋
  - Arithmetic: MultiArith, GSM8K
  - Commonsense: StrategyQA, BBH-Disambiguation QA
  - Logical: BBH-Logical Deduction
- 베이스라인
  - Zero-shot
  - Zero-shot-CoT (“Let’s think step by step”)
- 평가
  - LLM 기반 평가: OpenAI의 o1-mini

메인 결과

Model	Method	Arithmetic		Commonsense		Logical	Avg
		MultiArith	GSM8K	StrategyQA	DisambiguationQA	Logical Deduction	
Llama-3.1-8B	Zero-shot	15.56	6.97	26.35	36.00	28.40	22.66
	Zero-shot + Ours	**50.56**	**34.57**	**30.13**	**37.20**	**32.00**	**36.90**
	Zero-shot-CoT	77.22	**48.90**	24.31	32.00	16.80	39.85
	Zero-shot-CoT + Ours	**78.33**	34.34	**45.27**	**34.00**	**24.80**	**43.35**
Gemma-3-7B	Zero-shot	10.00	**48.98**	31.88	10.80	24.80	25.29
	Zero-shot + Ours	**15.00**	45.26	**34.79**	**16.80**	**27.20**	**27.81**
	Zero-shot-CoT	46.11	38.59	19.36	34.00	18.80	31.37
	Zero-shot-CoT + Ours	**73.33**	**44.81**	**23.44**	**36.00**	**24.00**	**40.32**
Mistral-7B-v0.3	Zero-shot	16.11	7.73	23.58	34.40	14.80	19.32
	Zero-shot + Ours	**27.78**	**15.31**	**25.62**	**37.20**	**18.00**	**24.78**
	Zero-shot-CoT	29.44	**17.21**	16.30	13.20	**28.80**	20.99
	Zero-shot-CoT + Ours	**37.22**	15.39	**36.83**	**32.00**	20.40	**28.37**

- AID는 프롬프트 없이 또는 프롬프트와 함께 사용해도 전반적으로 성능을 향상시킴
- 산술/상식/논리 측면에서 일관되게 성능을 향상시킴
- 프롬프트가 성능을 망치는 상황에서 성능을 복구시키거나 향상시킴

주입 단어

- 여러 후보 중 “Well”이 가장 안정적으로 성능을 향상시킴
  - “Well”은 중립적인 신호 (특정 방향x)
    → 더 추론 가능하게 함

❖ 강한 의미를 가진 문장/단어 보다, 가볍고 중립적인 “Well”이 더 좋음

Category	Injection Phrase	Accuracy
Single Word	Step	44.44
	Let	38.33
	Well	**50.56**
	Wait (Muennighoff et al., 2025)	21.11
Conjunction	And	16.11
	But	17.78
	Or	12.78
Conjunction Pool	Addition Pool	26.11
	Contrast Pool	20.56
	Mix Pool	23.33
Phrase	I mean,	27.22
	You know,	22.22
Sentence	I might be wrong.	33.33
	Keep reasoning.	12.22
Machine Language	<start of text>	27.78
	\t	19.44
	#	26.67

모델 별 k 값 조정

- Llama-3.1-8B: k = 2
- Gemma-3-7B: k = 2 (or 5)
- Mistral-7B-v0.3: k = 5 (or 2)

❖ 모델마다 임계점이 다름

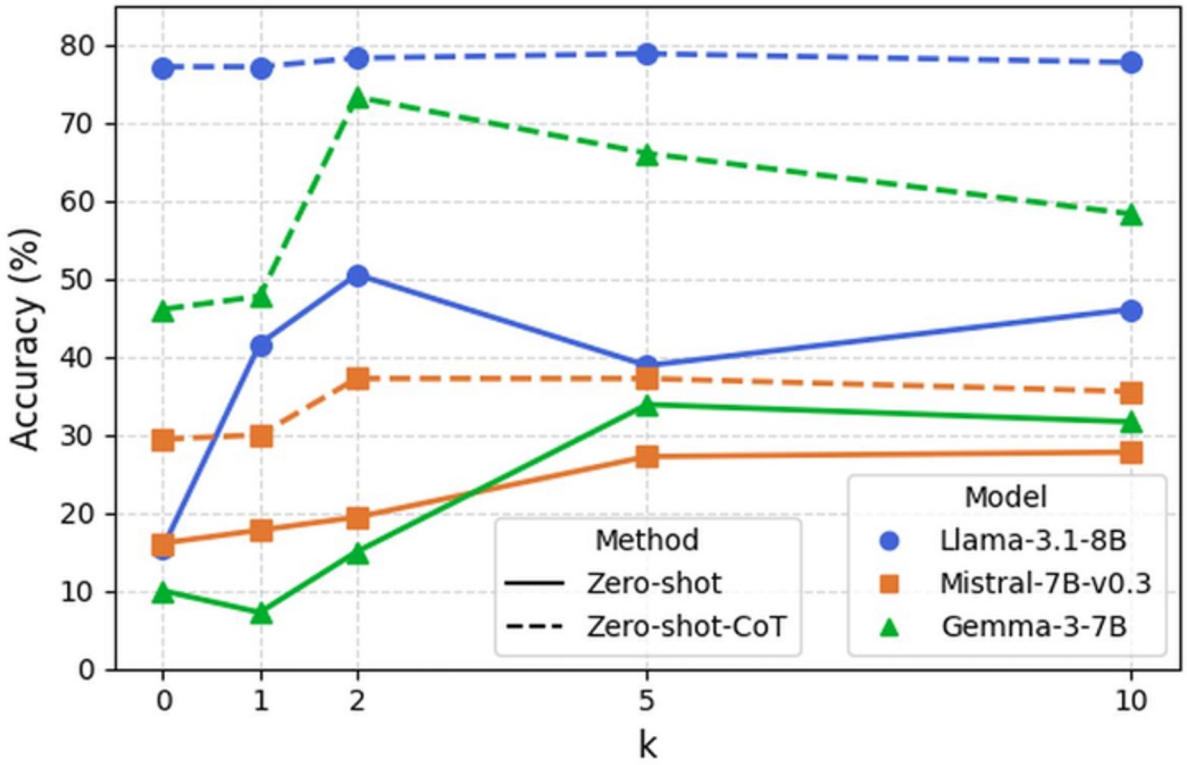

추가 데이터 셋

Method	Arithmetic				Commonsense				Logical	
	MultiArith	GSM8K	MATH	AQUA	CSQA	StrategyQA	BBH-Date	BBH-Disamb	BBH-Logic	BBH-Web
Zero-shot	15.56	6.97	4.00	15.35	**65.27**	26.35	**22.00**	36.00	28.40	31.20
Zero-shot + Ours	**50.56**	**34.57**	**12.80**	**24.41**	63.88	**30.13**	20.80	**37.20**	**32.00**	**34.80**
Zero-shot-CoT	77.22	**48.90**	**12.00**	**29.13**	49.55	24.31	37.20	32.00	16.80	14.80
Zero-shot-CoT + Ours	**78.33**	34.34	11.60	28.74	**51.84**	**45.27**	**44.80**	**34.00**	**24.80**	**28.00**

- Arithmetic: MATH, AQUA
- Commonsense: CommonsenseQA, BBH-Date Understanding
- Logic: BBH-Web of Lies

❖ 어려운 문제에서도 AID가 효과 있음

모델 크기

- 작은 모델(1B), 큰 모델(32B)에서도 성능 향상

❖ 전반적으로 통하는 디코딩 전략

Dataset	Model	Method	Accuracy (%)
MultiArith	Llama-3.2-1B	Zero-shot	1.67
		Zero-shot + Ours	**5.56**
		Zero-shot CoT	10.00
		Zero-shot CoT + Ours	**15.56**
	QwQ-32B	Zero-shot	87.78
		Zero-shot + Ours	**90.00**
		Zero-shot CoT	**96.67**
		Zero-shot CoT + Ours	95.56
AQUA	Llama-3.2-1B	Zero-shot	9.84
		Zero-shot + Ours	**18.50**
		Zero-shot CoT	**13.78**
		Zero-shot CoT + Ours	9.45
	QwQ-32B	Zero-shot	**48.82**
		Zero-shot + Ours	46.46
		Zero-shot CoT	61.81
		Zero-shot CoT + Ours	**65.36**

추론 품질

- 정답인 경우: SOCREBAL 점수가 높아짐
- 오답인 경우: SOCREBAL 점수가 낮아짐
- 무조건 토큰 수(길이) 증가 x

❖ 더 길게 말하는게 아닌, 필요한 부분에 개입해서 품질 향상

Init Prompt	Baseline	Baseline + Ours
Zero-shot (Correct)	3.57	**4.34**
Zero-shot (Incorrect)	**3.68**	2.55
Zero-shot-CoT (Correct)	4.14	**4.21**
Zero-shot-CoT (Incorrect)	**3.69**	2.53

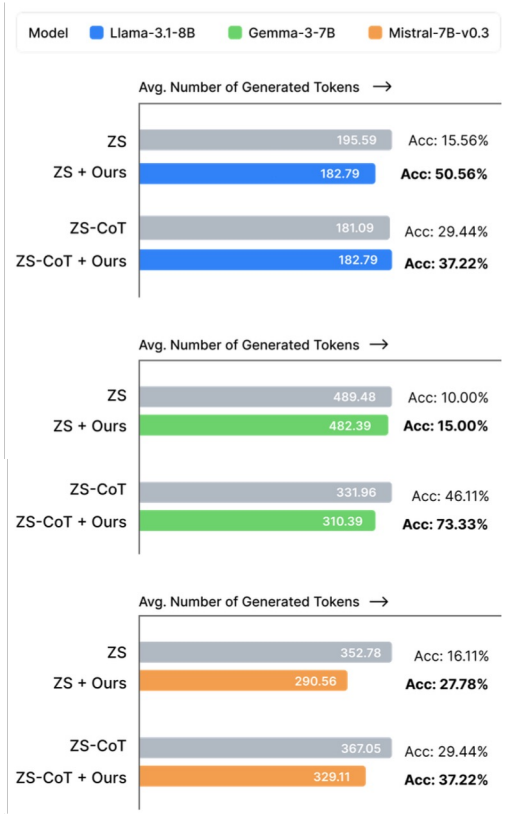

토큰 확실성

- “Well” 주입 후 평균 top-1 확률 크게 상승
- 주입 전: 확률 이동 불안정
- 주입 후: 확률 이동 안정

❖ 조기 종료 완화 및 추론 과정 안정화

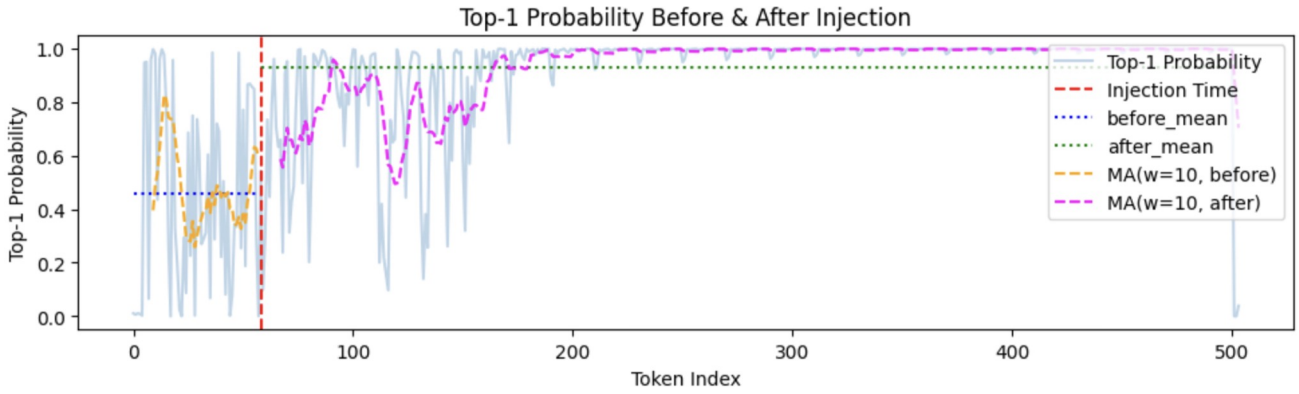

Method	Avg. Top-1 Probability (%)
Baseline	16.12
Ours	64.48

관련 연구

- 튜닝 기반: 모델 자체를 다시 학습
  - 대규모 데이터 + 연산 자원 필요
  - teacher 모델 품질에 크게 의존
- 프롬프트 기반: 프롬프트 설계로 모델이 더 잘 추론성능 향상
  - 인적 자원 필요 (프롬프트 엔지니어링)
  - 여러번의 호출로 inference 비용 증가
- 샘플링 기반: 여러 개의 추론을 샘플링해서 선택
  - 실제 서비스 환경에서 큰 비용 발생
- 테스트 타임 전략: 추론 과정 혹은 전처리과정에서 추론 품질 향상
  - 휴리스틱 설계, 추가 검증, 추가 계산 등 필요

결론 및 한계

- 결론
  - LLM의 미성숙한 추론 (immature reasoning) - silence, no reasoning, incomplete reasoning 문제
  - <eos> 조기 발생 시 “Well”을 주입 하는 AID 제안
  - 다양한 추론 벤치마크에서 베이스라인 모두 성능 향상
  - 파라미터 혹은 프롬프트 수정 없이, test-time decoding만으로 추론 능력 강화
- 향후 연구/한계
  - 테스크 및 언어별 주입 단어 혹은 임계치 설정
  - 다국어/다문화 환경에서의 일반성 미검증
  - multi-turn AID와 같은 더 복잡한 개입 전략과의 비교 필요